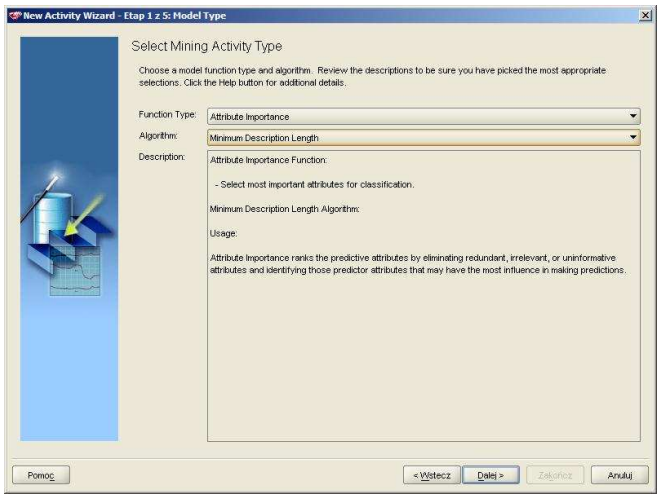
Eksploracja danych (laboratorium)

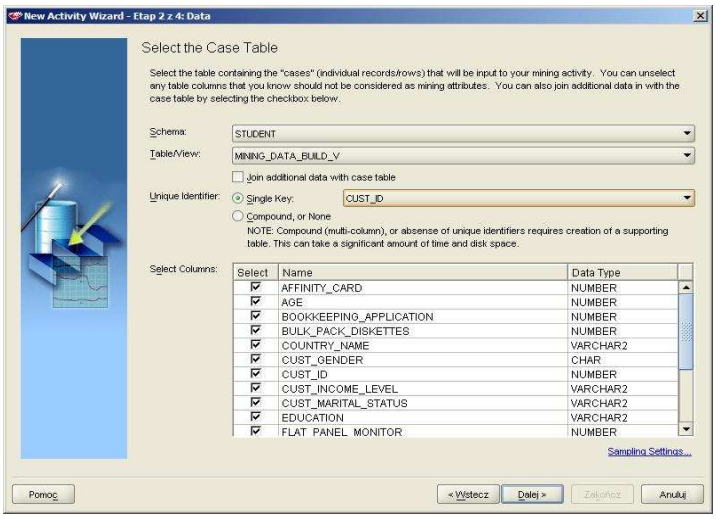
Określanie ważności atrybutów.

UWAGA: przykłady w ćwiczeniu wykonano przy użyciu generycznego konta o nazwie STUDENT. Za każdym razem, gdy w ćwiczeniu wymienione jest konto STUDENT, wykorzystaj do wykonania danego kroku swoje konto w bazie danych (właściwe obiekty zostały uprzednio załadowane na Twoje konto).

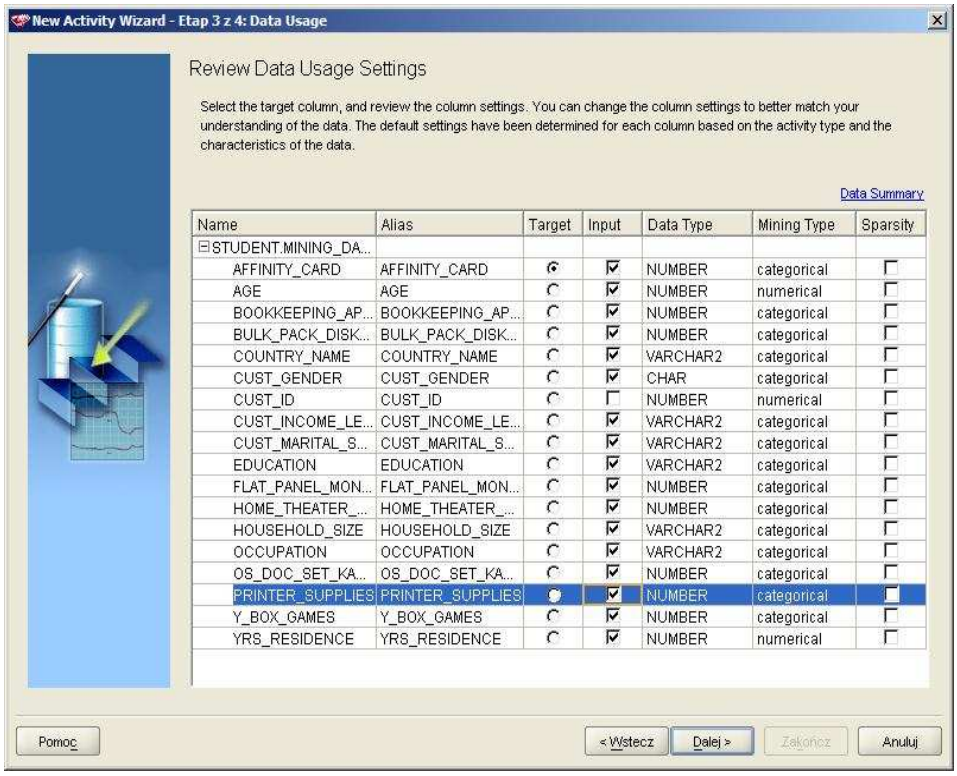
1. Uruchom narzędzie Oracle Data Miner i połącz się z serwerem bazy danych.
2. Z menu głównego wybierz Activity→Build. Na ekranie powitalnym kliknij Dalej>.
3. Z listy Function Type wybierz Attribute Importance. Jedyny dostępny algorytm, Minimum Description Length, zostaje automatycznie wybrany jako algorytm przetwarzający. Kliknij przycisk Dalej>.



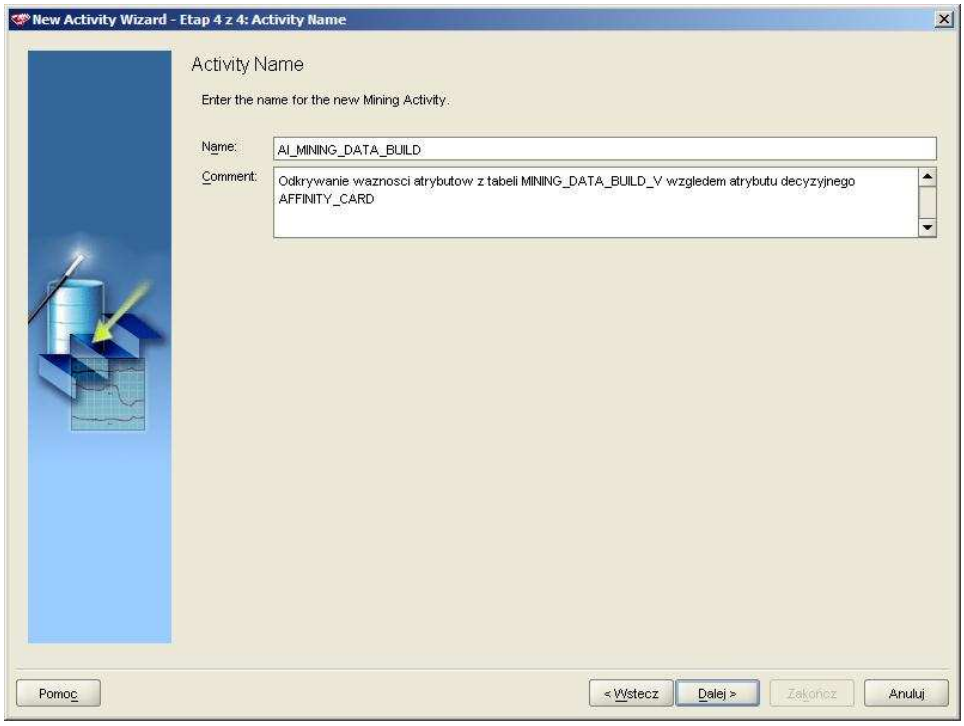
4. Z listy dostępnych schematów wybierz schemat STUDENT. Wybierz tabelę MINING_DATA_BUILD_V. Jako klucz podstawowy (Unique identifier) zaznacz przycisk radiowy Single Key i z listy wybierz atrybut CUST_ID. Upewnij się, że wszystkie atrybuty na liście Selected Columns są wybrane. Kliknij przycisk Dalej>.



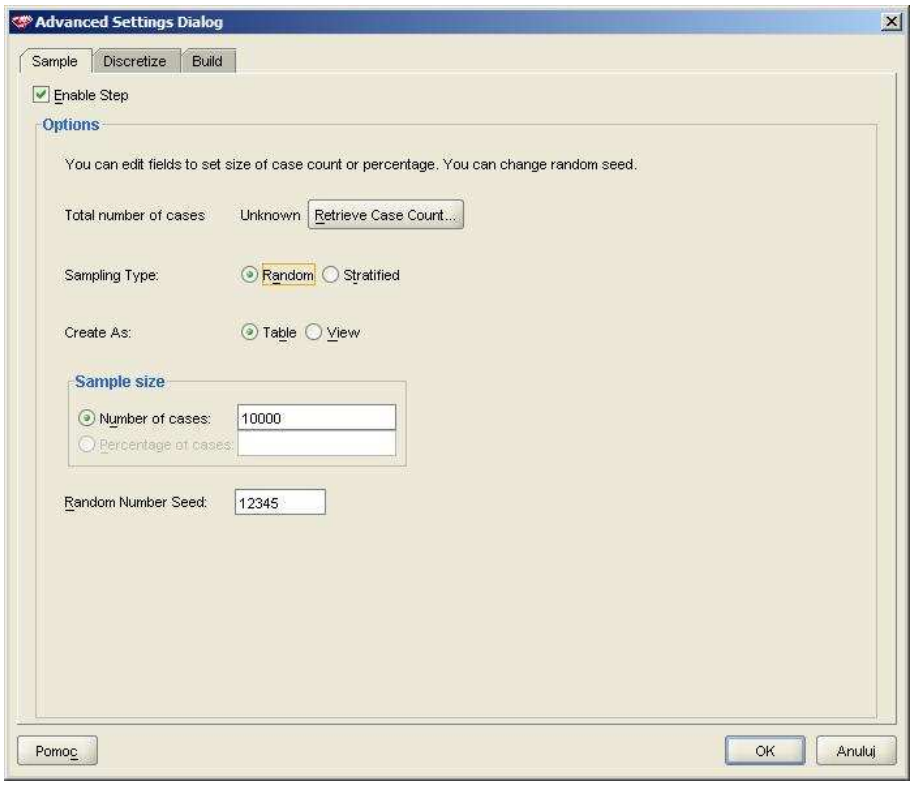
5. Kolumna Target zawiera informację o atrybucie decyzyjnym, względem którego staramy się określić ważność pozostałych atrybutów (predyktorów). Wskaż atrybut `AFFINITY_CARD` (oznacza, czy dany klient skorzysta z karty lojalnościowej) jako atrybut decyzyjny w kolumnie Target. Atrybut `PRINTER_SUPPLIES` został automatycznie odrzucony, ponieważ zawiera tylko jedną wartość. Włącz atrybut `PRINTER_SUPPLIES` do przetwarzania. Kliknij przycisk Dalej>.



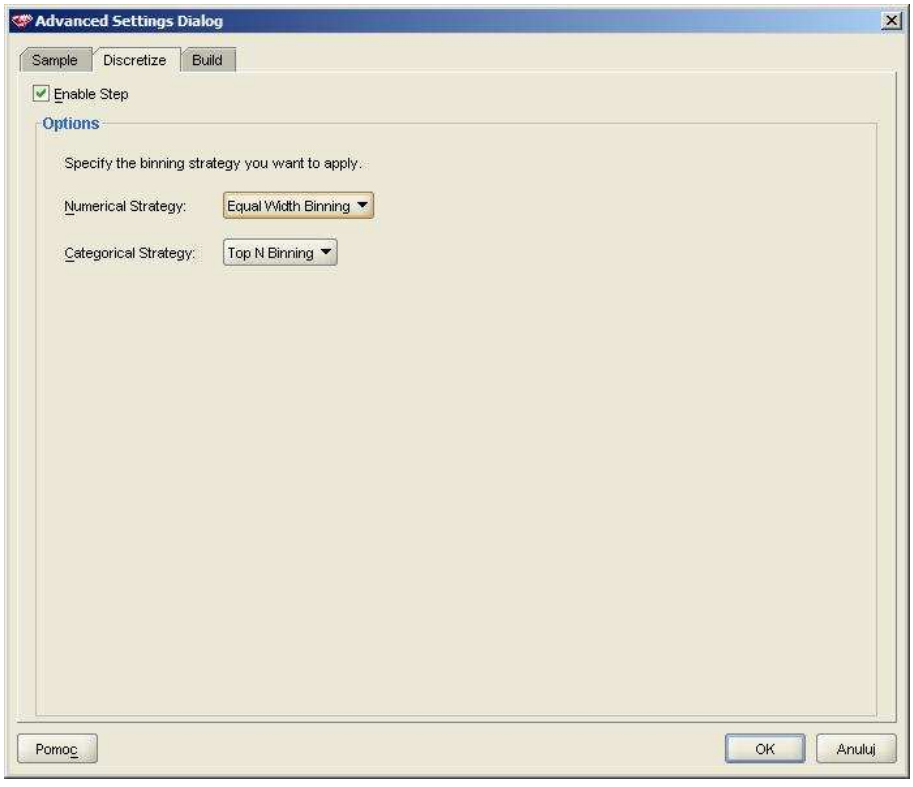
6. Wprowadź nazwę i opis dla procesu eksploracji. Kliknij przycisk Dalej>.



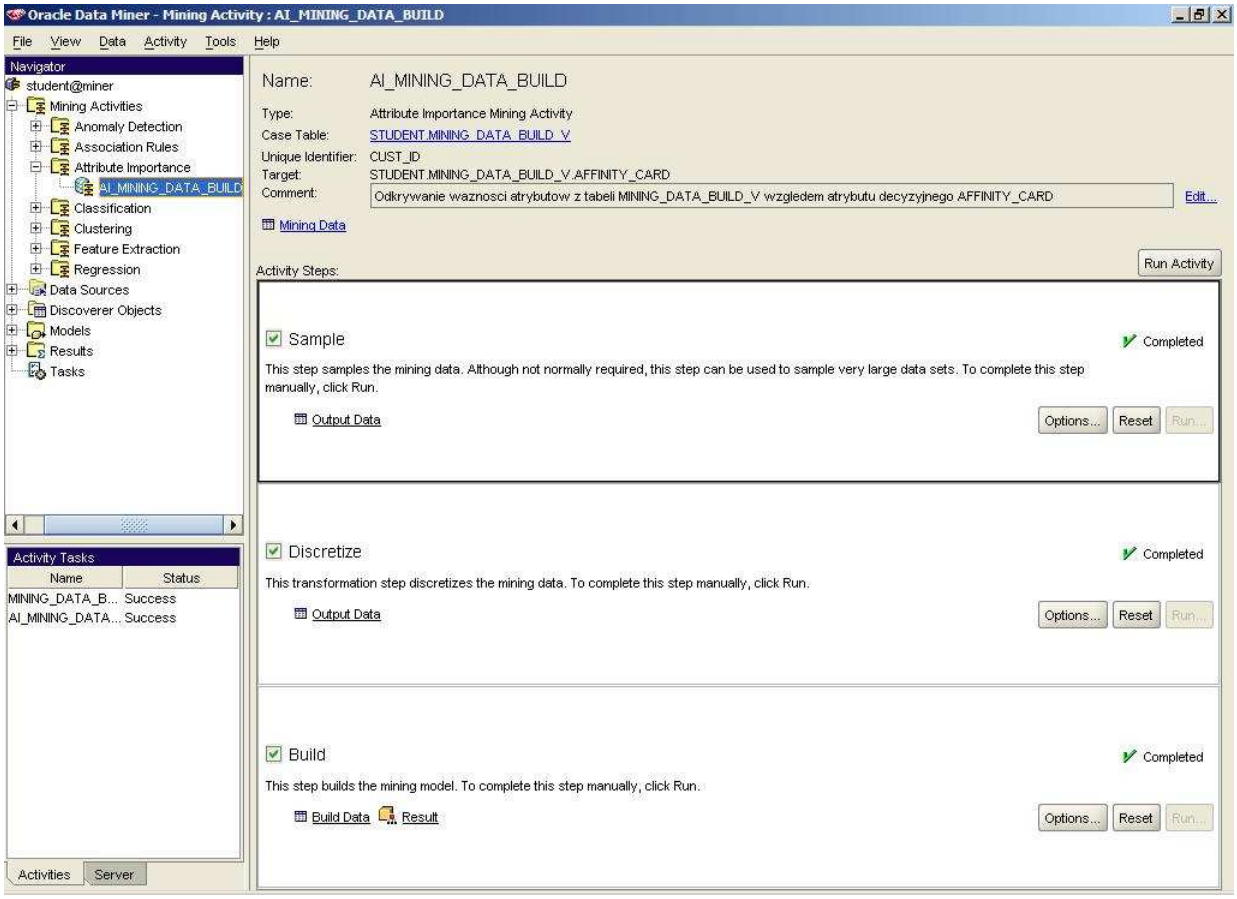
7. Kliknij przycisk Advanced Settings. Na zakładce Sample włącz opcję Enable Step. Zmień rodzaj próbkowania na losowy (opcja Sampling Type, wartość Random).



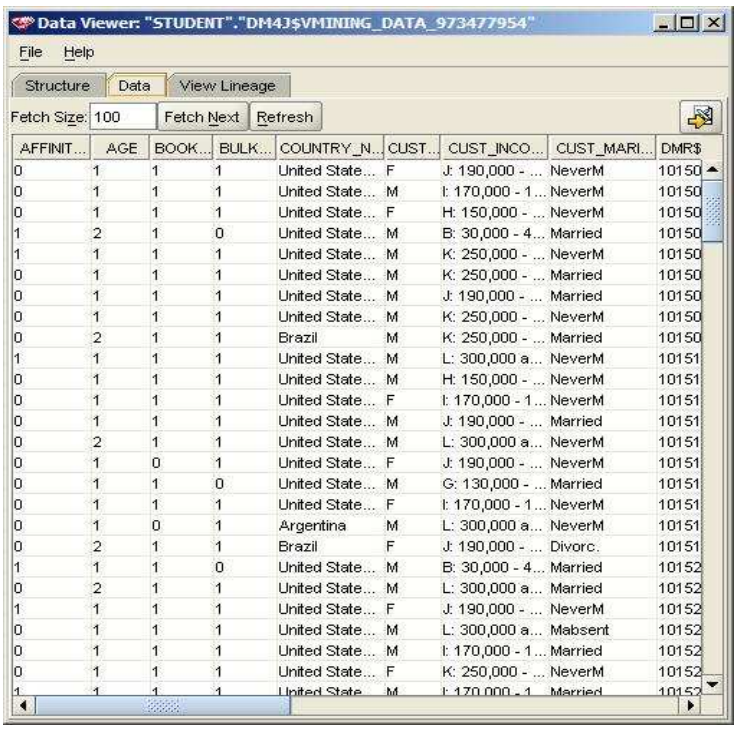
8. Przejdź na zakładkę Discretize. Upewnij się, że dyskretyzacja jest włączona i zostanie wykonana automatycznie przed uruchomieniem się właściwego algorytmu. Zmień sposób dyskretyzacji atrybutów numerycznych na Equal Width Binning.



9. Kliknij przycisk OK. Upewnij się, że jest zaznaczona opcja Run upon finish. Kliknij klawisz Zakończ. Ekran powinien mieć w tej chwili następujący wygląd. Bloki w prawym panelu reprezentują następujące po sobie etapy procesu eksploracji danych. Dla każdego etapu można zobaczyć dane stanowiące wynik działania danego etapu (odnośnik Output Data). Przycisk Run Activity powoduje uruchomienie całego procesu eksploracji. Istnieje też możliwość zmiany parametrów i usunięcia poprzednich wyników dla dowolnego procesu i uruchomienie całej eksploracji w sposób przyrostowy (przyciski Reset, Options i Run).

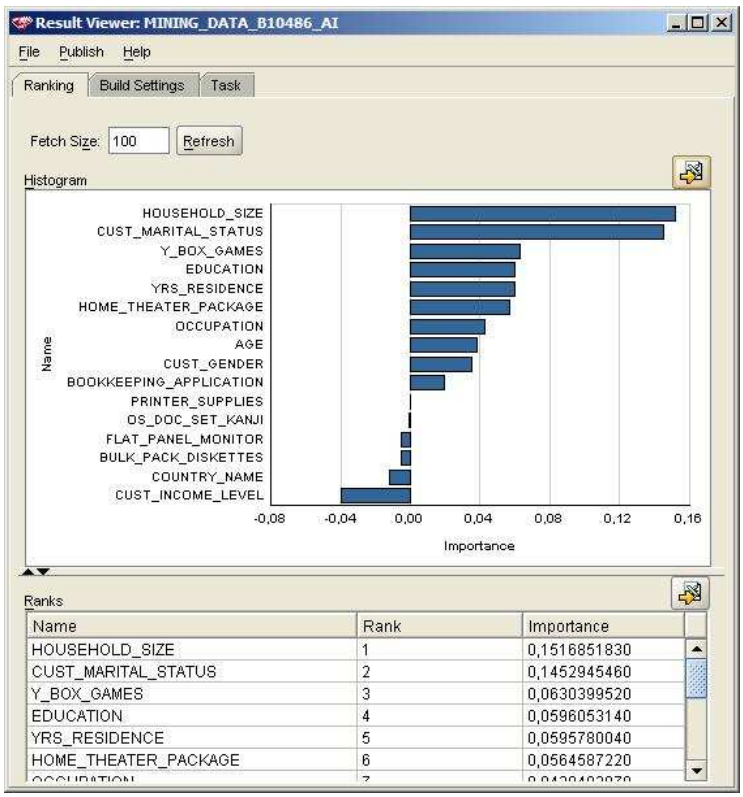


10. Kliknij na odnośnik Output Data w bloku Discretize. Kliknij na odnośnik do tymczasowej tabeli. W nowym okienku kliknij na zakładce Data. Zwróć uwagę, że atrybuty numeryczne (`AGE`, `YRS_RESIDENCE`) zostały automatycznie dyskretyzowane. Zamknij okienko z tabelą tymczasową.



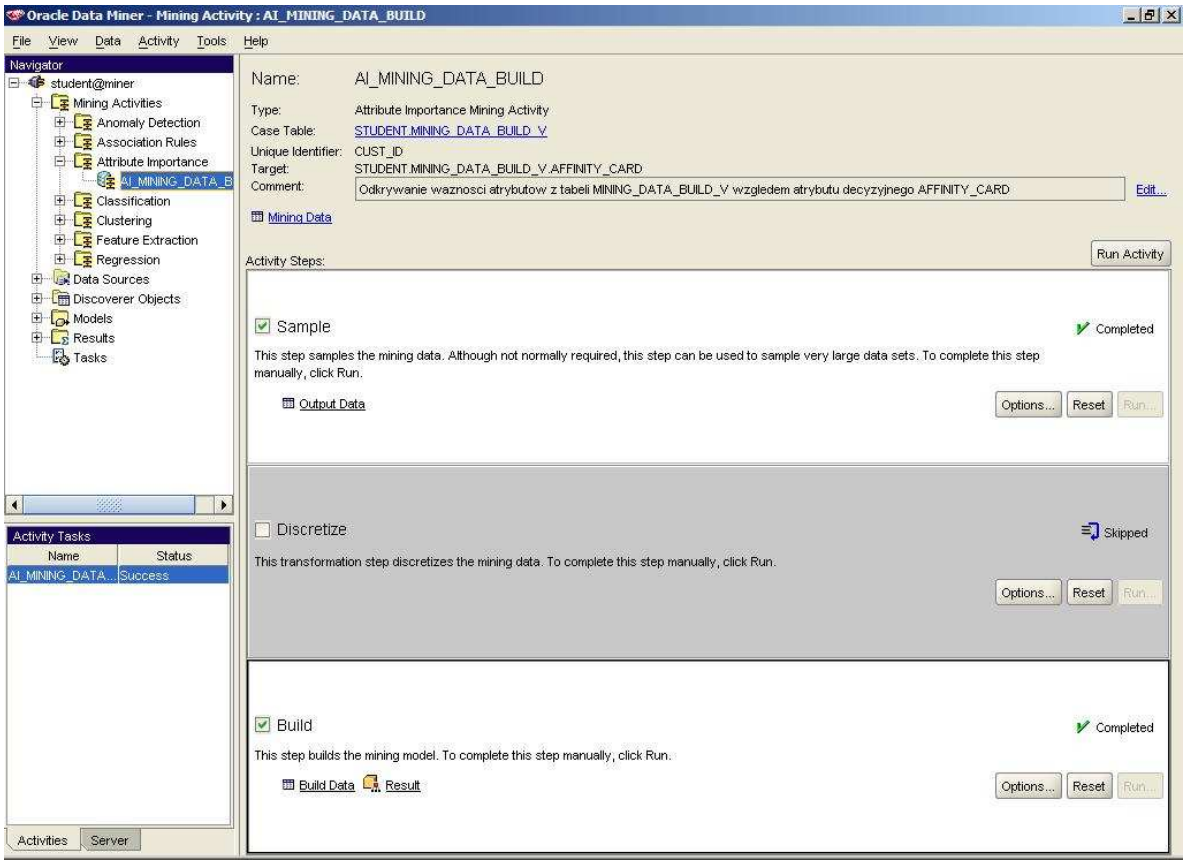
AFFINIT...	AGE	BOOK...	BULK...	COUNTRY_N...	CUST...	CUST_INCO...	CUST_MARI...	DMR$
0	1	1	1	United State...	F	J: 190,000 - ...	NeverM	10150
0	1	1	1	United State...	M	I: 170,000 - 1...	NeverM	10150
0	1	1	1	United State...	F	H: 150,000 - ...	NeverM	10150
1	2	1	0	United State...	M	B: 30,000 - 4...	Married	10150
1	1	1	1	United State...	M	K: 250,000 - ...	NeverM	10150
0	1	1	1	United State...	M	K: 250,000 - ...	Married	10150
0	1	1	1	United State...	M	J: 190,000 - ...	Married	10150
0	1	1	1	United State...	M	K: 250,000 - ...	NeverM	10150
0	2	1	1	Brazil	M	K: 250,000 - ...	Married	10150
1	1	1	1	United State...	M	L: 300,000 a...	NeverM	10151
0	1	1	1	United State...	M	H: 150,000 - ...	NeverM	10151
0	1	1	1	United State...	F	I: 170,000 - 1...	NeverM	10151
0	1	1	1	United State...	M	J: 190,000 - ...	Married	10151
0	2	1	1	United State...	M	L: 300,000 a...	NeverM	10151
0	1	0	1	United State...	F	J: 190,000 - ...	NeverM	10151
0	1	1	0	United State...	M	G: 130,000 - ...	Married	10151
0	1	1	1	United State...	F	I: 170,000 - 1...	NeverM	10151
0	1	0	1	Argentina	M	L: 300,000 a...	NeverM	10151
0	2	1	1	Brazil	F	J: 190,000 - ...	Divorc.	10151
1	1	1	0	United State...	M	B: 30,000 - 4...	Married	10152
0	2	1	1	United State...	M	L: 300,000 a...	Married	10152
1	1	1	1	United State...	F	J: 190,000 - ...	NeverM	10152
0	1	1	1	United State...	M	L: 300,000 a...	Mabsent	10152
0	1	1	1	United State...	M	I: 170,000 - 1...	Married	10152
0	1	1	1	United State...	F	K: 250,000 - ...	NeverM	10152

11. Kliknij na odnośnik Result w bloku Build. Przeanalizuj uzyskane wyniki. Które atrybuty są najbardziej przydatne do predykcji wartości atrybutu decyzyjnego? Atrybuty o ważności mniejszej niż 0 są uznawane za całkowicie nieprzydatne. Jaką ważność ma atrybut `PRINTER_SUPPLIES` posiadający tylko jedną wartość?



Name	Rank	Importance
HOUSEHOLD_SIZE	1	0,1516851830
CUST_MARITAL_STATUS	2	0,1452945460
Y_BOX_GAMES	3	0,0630399520
EDUCATION	4	0,0596053140
YRS_RESIDENCE	5	0,0595780040
HOME_THEATER_PACKAGE	6	0,0564587220

12. Kliknij na  umieszczoną w prawym górnym rogu. Jako format pliku graficznego do eksportu wybierz GIF. Kliknij przycisk OK. Zapisz plik na dysku lokalnym. Obejrzyj wygenerowany plik. Zamknij okienko prezentujące wynik działania algorytmu.
13. W bloku Sample kliknij przycisk Reset. W okienku z pytaniem o potwierdzenie usunięcia wyniku działania kroku próbkowania (i wszystkich kroków następujących po próbkowaniu) kliknij przycisk Tak. Wyniki wszystkich kroków zostaną usunięte. W bloku Sample kliknij przycisk Options i zmień sposób próbkowania na próbkowanie warstwowane (opcja Sampling Type, wartość Stratified). Kliknij przycisk OK. Odznacz pole wyboru obok nazwy bloku Discretize (w ten sposób w trakcie kolejnego uruchomienia algorytmu nie zostanie przeprowadzona automatyczna dyskretyzacja). Kliknij przycisk Run Activity umieszczony w prawej górnej części ekranu. Po wykonaniu tych czynności ekran powinien wyglądać jak na obrazku poniżej. Porównaj uzyskany wynik z poprzednim wynikiem. Czy obserwujesz jakieś zmiany?



14. Z menu głównego wybierz Tools→SQL Worksheet. W górnym oknie wprowadź po kolei następujące komendy:

```
CREATE TABLE ATTRIBUTE_IMPORTANCE_TEST AS
SELECT * FROM MINING_DATA_BUILD_V;

ALTER TABLE ATTRIBUTE_IMPORTANCE_TEST
ADD COL1 NUMBER;

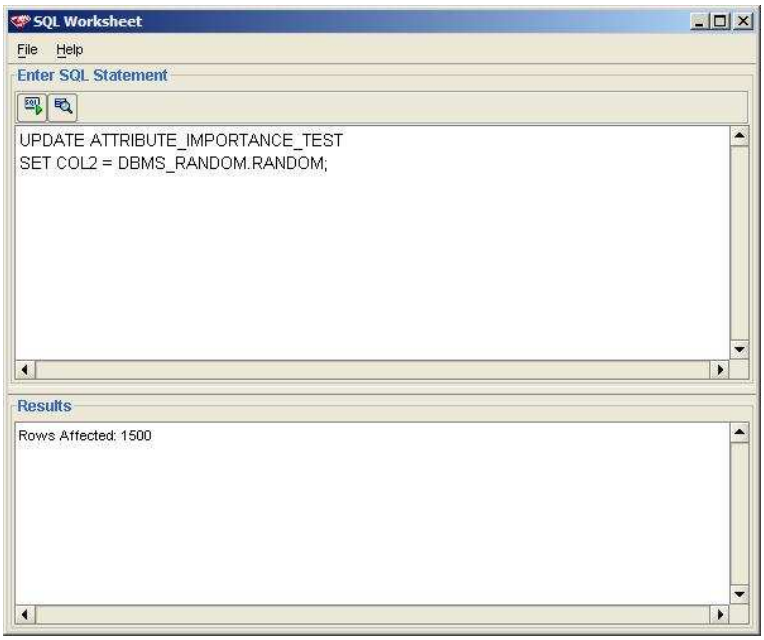
ALTER TABLE ATTRIBUTE_IMPORTANCE_TEST
ADD COL2 NUMBER;

UPDATE ATTRIBUTE_IMPORTANCE_TEST
SET COL1 = 1 - AFFINITY_CARD;

UPDATE ATTRIBUTE_IMPORTANCE_TEST
SET COL2 = DBMS_RANDOM.RANDOM;

COMMIT;
```

15. W nowo utworzonej tabeli znajdują się dwa dodatkowe atrybuty: COL1 i COL2. Atrybut COL1 jest liniowo zależny od atrybutu decyzyjnego (czyli pozwala ze 100% dokładnością przewidzieć wartości atrybutu decyzyjnego), podczas gdy atrybut COL2 jest całkowicie losowy (czyli nie posiada żadnej wartości informacyjnej).



16. Utwórz nowe zadanie eksploracji (z głównego menu wybierz Activity→Build) i określ ważność atrybutów względem atrybutu decyzyjnego AFFINITY_CARD w tabeli ATTRIBUTE_IMPORTANCE_TEST. W procesie eksploracji wykorzystaj próbkowanie i automatyczną dyskretyzację atrybutów. Sprawdź, w którym miejscu w rankingu atrybutów znajdą się atrybuty COL1 i COL2.